

《大数据与管理决策基础》

第 2 讲：企业数据与业务对象

课程讲义

目录

第 2 讲 企业数据与业务对象	3
2.1 学习目标	3
2.2 为什么管理决策需要数据建模	4
2.3 企业运营数据的基本语义	4
2.4 关系模型的基本语言	5
2.5 键、外键与完整性约束	6
2.6 订单、客户、产品与库存的 ER 模型	6
2.7 规范化与函数依赖	7
2.8 事务型建模与分析型建模	8
2.9 事实表粒度	8
2.10 度量的可加性	9
2.11 事件、状态与时间	10
2.12 从关系表到业务对象	11
2.13 指标字典、元数据与治理	11
2.14 课堂案例：零售订单数据模型	12
2.15 配套代码	12
习题	13
本讲小结	14
常见误区	14
参考文献	14

第 2 讲 企业数据与业务对象

本讲讨论企业运营数据的建模基础。第一讲已经指出，数据分析的终点不是报表或模型本身，而是可执行、可评估、可反馈的管理行动。本讲进一步说明这些行动必须依赖稳定的数据对象：客户、订单、产品、库存、供应商、流程事件和业务状态。讲义从实体、属性、关系、事件、状态和指标等基本概念出发，介绍关系模型、键与完整性约束、ER 模型、规范化关系模型、星型模型、事实表粒度、度量可加性、时间建模和指标治理。通过本讲，学生应理解数据建模既是数据库设计问题，也是管理概念、组织责任和分析可信度的共同基础。

课程接口

本讲把第一讲的管理行动闭环落到对象层。后续 SQL KPI、数据质量、统计看板、预测模型、优化决策、流程挖掘和 MLOps 都要回答同一个前置问题：模型和指标究竟作用于哪些业务对象，这些对象在数据表中如何被识别、连接、更新和审计。

2.1 学习目标

第一讲讨论如何把经营症状转化为可行动的分析问题。第二讲回答一个更基础的问题：这些分析问题依赖什么样的数据结构？如果企业数据只是一些零散表格，那么后续 SQL、KPI、预测模型和优化模型都会缺少稳定基础。本讲的目标不是训练学生画一个漂亮的 ER 图，而是训练学生把管理概念转化为可查询、可治理、可建模、可行动的数据对象。

完成本讲后，学生应能够：

1. 区分实体、属性、关系、事件、状态、事实和指标；
2. 使用关系模式、主键、外键和完整性约束描述企业数据；
3. 解释 ER 模型、规范化关系模型和星型模型各自适用的场景；
4. 为订单、客户、产品和库存设计基本数据模型，并声明事实表粒度；
5. 判断事实表度量的可加性，避免对比率、均值和快照余额进行错误聚合；
6. 说明事件时间、状态时间和入库时间的差异，以及慢变维对历史分析的影响；
7. 将关系表进一步映射为业务对象、对象关系、对象状态和可执行行动。

2.2 为什么管理决策需要数据建模

在企业中，“有数据”并不等于“可决策”。同一个客户可能在 CRM、订单系统、售后系统和营销系统中拥有不同编号；同一笔销售可能被财务部门、运营部门和渠道部门以不同口径统计；同一件库存商品可能同时存在采购在途、仓库可用、销售锁定和质检冻结等状态。若没有明确的数据模型，后续分析会出现三类问题。

- 1. 对象不稳定：系统无法判断同一个客户、订单或产品在不同系统中是否指向同一业务对象。
- 2. 口径不稳定：不同报表对销售额、库存、延期、流失等指标使用不同定义。
- 3. 行动不稳定：分析结果无法对应到可执行对象，例如无法说明对哪个订单加急、对哪个客户回访、对哪个库存位置补货。

定义 2.1 (企业数据模型). 企业数据模型是对企业业务对象、对象属性、对象关系、业务事件、状态变化、指标口径和约束规则的结构化表达。它既可以表现为 ER 图、关系模式、维度模型，也可以表现为数据字典、指标字典和业务对象定义。

这个定义强调，数据建模不是数据库工程师的局部工作，而是企业管理语言的工程化表达。没有数据模型，企业很难判断“客户”“订单”“库存”“销售额”“延期”这些词在不同系统和部门中是否具有同一含义。没有共同含义，就不可能有可信指标；没有可信指标，就不可能有可审计的决策。

2.3 企业运营数据的基本语义

企业运营数据看起来复杂，但从建模角度可以先分为六类。这个分类帮助学生判断一张表的角色：它是在描述一个对象，记录一次业务活动，保存某个时间点的状态，表达对象之间的连接，还是表达一个已经聚合过的指标。

表 2.1: 企业运营数据的基本语义

类型	数据含义	示例
实体	具有相对稳定身份的对象。	客户、产品、供应商、仓库、设备、员工。
属性	描述实体、关系或事件的变量。	地区、品类、单价、客户等级、付款方式。
关系	对象之间的结构性连接。	客户产生订单、产品属于品类、供应商供应物料。
事件	在时间上发生的一次业务活动。	下单、付款、发货、退货、维修、审批。
状态	某一时点或区间内对象的状态。	库存量、订单状态、设备状态、客户等级。

类型	数据含义	示例
指标	对事件或状态的聚合度量。	销售额、准时交付率、库存周转率、流失率。

定义 2.2 (业务事件). 业务事件是在特定时间发生、能够改变或记录业务状态的一次活动。事件通常具有事件主体、事件对象、发生时间、数量或金额等属性。

一个订单明细事件可写为

$$e_i = (o_i, c_i, p_i, q_i, t_i, s_i),$$

其中 o_i 是订单, c_i 是客户, p_i 是产品, q_i 是数量, t_i 是事件时间, s_i 是交付或履约状态。这个表达式虽简单, 却包含了企业数据建模的核心: 客户和产品是相对稳定的实体, 订单明细是交易事件, 数量和时间是事件属性, 交付状态可能来自后续物流事件或累计快照。

评注 2.3. 很多数据错误不是由计算公式造成的, 而是由语义混淆造成的。例如, 把库存余额当作销售事件求和, 把客户当前等级用于解释历史订单, 或把订单头表与订单明细表混在同一粒度上聚合, 都会导致看似精确但实际错误的指标。

2.4 关系模型的基本语言

Codd 提出的关系模型为数据库提供了严格而简洁的形式语言。在关系模型中, 数据被表示为关系, 关系可以理解为带有属性名的元组集合。一个关系模式可写为

$$R(A_1 : D_1, A_2 : D_2, \dots, A_k : D_k),$$

其中 A_j 是属性名, D_j 是该属性的取值域。关系实例是满足该模式的一组元组:

$$r(R) = \{t_1, t_2, \dots, t_n\}.$$

更严格地说, 元组 t 可被看作从属性集合到相应取值域的映射:

$$t(A_j) \in D_j, \quad j = 1, \dots, k.$$

若客户集合为 C , 产品集合为 P , 时间集合为 T , 订单明细集合可被看作有限关系:

$$O \subseteq C \times P \times \mathbb{N} \times T \times S,$$

其中 S 表示订单状态或履约状态的取值集合。

关系模型的重要优点是声明性。用户用 SQL 说明“需要什么结果”, 而数据库系统决定如何执行连接、过滤、聚合和排序。这使企业数据可以被多个应用复用, 也使管理分析能够建立在稳定的集合运算之上。但关系模型本身并不自动保证业务语义清楚。关系模式说明字段之间如何组织, 业务模型还必须说明字段代表什么管理概念。

2.5 键、外键与完整性约束

在数据库设计中，至少需要关注三类约束。它们看起来像技术细节，但实际上直接影响管理分析的可信度。

- 1. 实体完整性：主键不能为空且唯一。
- 2. 引用完整性：外键必须引用已存在的主表记录。
- 3. 业务完整性：数量、价格、日期等字段满足业务规则，例如数量为正、实际交付日期不早于下单日期。

定义 2.4 (键). 给定关系 R ，若属性集合 K 的取值能够唯一识别 R 中的每个元组，则 K 是超键。若 K 是超键且任意真子集都不是超键，则 K 是候选键。数据库设计者在候选键中选定用于标识元组的键称为主键。

定义 2.5 (外键). 外键是一个关系中的属性集合，其取值引用另一个关系中的候选键或主键。外键把不同关系中的业务对象连接起来，是跨表分析和完整性检查的基础。


表 2.2: 自然键与代理键的比较

类型	优点	风险
自然键	具有业务含义，便于人工理解。	业务规则变化时可能失效，例如手机号、证件号、商品编码变更。
代理键	稳定、短小，便于连接和仓库建模。	需要维护与业务标识之间的映射，不能替代业务唯一性校验。

例如，如果订单表中的客户编号在客户表中不存在，那么按客户分层计算销售额时会出现无法归属的订单；如果同一个订单编号重复出现，则订单量、销售额和延期率都会被扭曲。因此，完整性约束不是数据库管理员的局部事务，而是指标可信度和模型可信度的前提。

2.6 订单、客户、产品与库存的 ER 模型

ER 模型强调从现实业务对象和对象关系出发建模，而不是直接从物理表结构出发建模。它尤其适合在课程早期训练学生识别实体、属性、关系、基数和可选性。



该模型的关键点不是画图本身，而是明确若干会影响分析结果的建模选择：

- 订单事实表的粒度是一行一张订单，还是一行一个订单明细项；
- 客户、产品等维度表是否能够稳定描述事实表中的对象；
- 库存是事件表、状态快照表，还是二者都需要；
- 每个关系是否能被主键和外键约束检查；
- 是否存在多对多关系，例如一个促销活动影响多个订单，一个订单使用多个优惠。

ER 模型一般经历概念模型、逻辑模型和物理模型三个层次。概念模型面向业务语言，强调对象和关系；逻辑模型转化为关系模式、键和约束；物理模型进一步考虑数据库类型、索引、分区、存储和性能。

表 2.3: 三类模型层次

层次	主要问题	典型产物
概念模型	业务上有哪些对象和关系？	ER 图、对象定义、关系说明。
逻辑模型	如何转化为关系模式和约束？	表、字段、主键、外键、基数。
物理模型	如何在具体平台上实现？	索引、分区、存储格式、权限。

2.7 规范化与函数依赖

规范化关系模型主要服务于一致性维护和事务处理。它通过减少冗余来避免插入异常、删除异常和更新异常。例如，若客户地址被重复写入每一笔订单，客户地址更新时就可能出现不同订单保存不同地址的矛盾。

规范化的基本思想可以用函数依赖表达。若属性集合 X 的取值确定属性集合 Y 的取值，则记为

$$X \rightarrow Y.$$

在客户表中，若客户编号确定客户名称和注册地区，则有

$$\text{customer_id} \rightarrow \{\text{customer_name}, \text{registered_region}\}.$$

定义 2.6 (第三范式的直观要求). 一个关系模式接近第三范式, 是指非键属性应直接依赖于键, 而不应通过另一个非键属性间接依赖于键。其直观目标是减少冗余和更新异常。

例如, 在订单表中同时存储 product_id、product_name 和 category 通常会导致冗余, 因为产品名称和品类应由产品编号决定, 而不是由每一行订单重复决定。更合适的做法是将产品属性放入产品表, 再通过 product_id 与订单事实连接。

需要注意, 规范化并不是越高越好。事务系统强调写入一致性, 分析系统强调查询便利性和指标解释。二者的建模目标不同。

2.8 事务型建模与分析型建模

面向事务处理的系统通常需要高一致性、低延迟写入和明确业务流程; 面向分析的系统通常需要跨主题查询、历史追踪和大量聚合。规范化模型与星型模型并不是谁更高级的关系, 而是服务于不同目标。

表 2.4: 事务型建模与分析型建模的差异

维度	事务型关系模型	分析型星型模型
主要目标	支持写入、一致性和业务流程。	支持查询、聚合和指标分析。
冗余控制	尽量减少冗余。	允许适度冗余以简化查询。
典型结构	多张规范化业务表。	事实表加维度表。
时间处理	多关注当前业务状态。	强调历史快照和版本追踪。
关键风险	更新异常、引用错误。	粒度混乱、口径不一致。

在管理分析中, 常见做法是将交易事件建模为事实表, 将描述对象的表建模为维度表。典型星型模型为

$$\text{FactOrderLine} \leftarrow \{\text{DimCustomer}, \text{DimProduct}, \text{DimDate}, \text{DimChannel}, \text{DimWarehouse}\}.$$

定义 2.7 (事实表与维度表). 事实表记录可度量的业务事件或状态, 通常包含外键、时间键和度量字段。维度表描述事实表中的分析角度, 例如客户、产品、地区、渠道、日期和仓库。

2.9 事实表粒度

事实表的设计首先要确定粒度 (grain)。粒度指事实表中一行记录所代表的最小业务事实。例如:

- 一行表示一个订单;

- 一行表示一个订单明细项；
- 一行表示一个产品、仓库、日期的库存快照；
- 一行表示一个客户、活动、日期的营销触达事件；
- 一行表示一个流程实例中的一个活动完成事件。

定义 2.8 (事实表粒度). 事实表粒度是事实表中每一行所代表的业务事实的最小单位。粒度必须在识别维度和度量之前声明，因为它决定哪些字段可以放入事实表，哪些指标可以被正确计算。

Kimball 的四步维度建模方法可概括为：

1. 选择业务过程；
2. 声明事实表粒度；
3. 识别维度；
4. 识别事实或度量。

第二步最容易被忽略。粒度决定了 KPI 的可计算性和可解释性。例如，销售额可定义为

$$\text{Revenue} = \sum_i q_i \cdot price_i,$$

但库存周转率需要同时使用销售成本和平均库存：

$$\text{Inventory Turnover} = \frac{\text{Cost of Goods Sold}}{\text{Average Inventory}}.$$

前者通常来自交易事实表，后者则需要库存状态快照或周期平均值。若把交易事件与状态快照混在一张事实表中，指标计算就会出现重复计数或时间口径错误。

2.10 度量的可加性

事实表中的度量并不都能用同一种方式聚合。可加性是指标建模中最容易被低估的概念。

表 2.5: 事实表度量的可加性

类型	含义	示例
可加度量	可沿所有维度求和。	销售金额、销售数量、成本。
半可加度量	只可沿部分维度求和。	库存余额可按产品求和，但不宜跨日期直接求和。
不可加度量	不能直接求和，通常需重新计算。	比率、百分比、均值、毛利率。

命题 2.9 (比率指标不能直接平均). 设第 d 日准时交付率为 $r_d = m_d/n_d$, 其中 m_d 是准时交付订单数, n_d 是总订单数。一个周期的总体准时交付率应为

$$\frac{\sum_d m_d}{\sum_d n_d},$$

一般不等于每日准时交付率的简单平均

$$\frac{1}{D} \sum_{d=1}^D r_d.$$

该命题说明, 指标字典不仅要写出指标名称, 还要写出聚合规则。准时交付率、转化率、毛利率、流失率等比率指标都应尽量保留分子和分母, 以便在不同维度和时间窗口上重新计算。

2.11 事件、状态与时间

企业系统中的时间数据至少有三种含义: 事件发生时间、状态有效时间和数据入库时间。它们对应不同问题。

表 2.6: 事件表与状态表的差异

表类型	适用问题	示例
交易事实表	记录一次业务活动。	一行订单明细、一笔付款、一条发货记录。
周期快照表	记录固定周期的状态。	每日产品、仓库库存余额。
累计快照表	跟踪有开始和结束的流程。	订单从下单、拣货、发货到签收的里程碑时间。
维度历史表	记录属性随时间变化。	客户等级、产品品类、组织归属的历史版本。

慢变维 (Slowly Changing Dimension, SCD) 用于处理维度属性随时间变化的问题。例如客户从普通客户变为关键客户后, 历史订单应按下单当时的客户等级分析, 还是按照当前客户等级分析? 不同业务问题需要不同口径。因此, 时间建模不是技术细节, 而是企业指标解释的一部分。

表 2.7: 慢变维的常见处理方式

方式	含义	适用问题
覆盖更新	只保留最新属性值。	只关心当前状态的运营查询。
保留历史版本	通过生效时间和失效时间保存属性历史。	需要按历史口径解释订单或客户行为。
保留当前和历史字段	同时保留当前属性和部分历史属性。	需要兼顾当前管理视角和有限历史比较。

2.12 从关系表到业务对象

关系表适合存储和查询，但管理行动通常作用于业务对象。一个订单对象可能来自订单表、订单明细表、客户表、产品表和物流状态表的组合；一个库存位置对象可能来自库存快照表、产品表、仓库表和锁定规则表的组合。

表 2.8: 关系表到业务对象的映射

业务对象	来源表	可支持行动
Customer	customers, customer_segments	分层运营、优惠券、客户回访。
Product	products, product_categories	定价、促销、补货策略。
Order	orders, order_lines, logistics	加急、拆单、客户沟通。
InvPosition	inventory, products, warehouses	补货、调拨、清仓。
Supplier	suppliers, purchase_orders	供应商替换、交期协商。

因此，现代企业决策系统关注

Tables → Objects → Links → States → Actions.

这一映射非常重要。SQL 查询返回的是行和列，而管理者执行的是对订单、客户、产品、库存位置等对象的行动。只有建立从表到对象的映射，后续的风险评分、权限控制、行动推荐和审计日志才有明确载体。

2.13 指标字典、元数据与治理

数据建模最终必须进入治理机制。DAMA-DMBOK 将数据治理、数据架构、数据建模与设计、数据质量、元数据、数据仓库、BI 和数据科学等看作相互关联的数据管理知识域。对于本课程而言，最重要的是理解三类文档。

- 1. 数据字典：说明表、字段、类型、取值范围、主外键和业务含义。
- 2. 指标字典：说明指标名称、业务定义、计算公式、数据来源、刷新频率、责任人和适用范围。
- 3. 血缘说明：说明指标或模型特征从哪些源表经过哪些转换产生。

在企业项目中，数据字典和指标字典不是可有可无的附录。它们决定不同团队能否对同一事实达成一致，也决定模型结果是否可以追溯、审计和复现。

表 2.9: 指标字典的最小规范

字段	说明
指标名称	统一使用的业务名称。
业务定义	指标所刻画的经营含义。
计算公式	分子、分母、聚合规则、时间窗口和过滤条件。
数据来源	源表、字段、刷新频率和必要清洗规则。
粒度与维度	可以按哪些对象、时间和组织层级分析。
责任人	数据负责人、业务负责人和异常处理机制。
行动接口	指标变化后触发的预警、审批、复盘或业务动作。

2.14 课堂案例：零售订单数据模型

考虑一家零售企业。第一讲中的经营症状是“库存金额持续上升，但热门商品仍然缺货”。若要进入数据分析，首先必须建立能够支持库存、销售和补货决策的数据模型。

表 2.10: 零售库存问题的数据建模拆解

建模要素	示例
业务对象	客户、产品、仓库、订单、订单明细、库存位置。
交易事实	订单明细、付款、退货、补货入库、调拨出入库。
状态快照	每日产品、仓库库存余额，在途库存，锁定库存。
核心维度	日期、产品、品类、仓库、地区、渠道、客户分层。
关键指标	销售额、销量、缺货率、库存周转率、滞销库存金额。
可执行行动	补货、调拨、促销、清仓、供应商催交。

在这个案例中，订单明细事实表回答“卖出了什么”，库存快照表回答“某天某仓库还剩多少”，补货事件表回答“何时补了多少”，产品维度表回答“这是什么品类和价格带”。如果把这些问题放在同一张宽表中，短期内可能方便查询，但长期会造成粒度混乱、历史状态丢失和指标解释困难。

2.15 配套代码

配套代码位于：

```
src/bdm_decision/cases/week02_enterprise_data_model.py
```

代码的目的不是实现数据库系统，而是把本讲中的实体、字段、关系和业务对象映射转化为可执行的结构化表示。其核心抽象如下：

代码 2.1: 实体、字段和关系

```
@dataclass(frozen=True)
```

```
class Entity:
    name: str
    primary_key: str
    fields: list[Field]
    description: str

@dataclass(frozen=True)
class Relationship:
    source: str
    target: str
    cardinality: str
    foreign_key: str
    description: str
```

运行方式：

代码 2.2: 运行第二周案例代码

```
PYTHONPATH=src python3 src/bdm_decision/cases/
week02_enterprise_data_model.py
```

学生阅读代码时应注意，`Entity` 和 `Relationship` 对应的是逻辑模型层，而 `business_object_mapping()` 对应的是从表到对象的管理接口。后续课程中的 SQL、指标和模型都可以接在这些对象之上。

习题

习题 2.10. 请以“零售订单、客户、产品与库存”为背景完成：

1. 列出至少四个实体及其主键；
2. 为每个实体设计至少四个字段；
3. 标明实体之间的基数关系；
4. 指出一个交易事实表、一个周期快照表和至少三个维度表；
5. 声明事实表粒度，并说明每个度量是否可加；
6. 将至少两个关系表映射为业务对象，并说明其可执行行动；
7. 为“销售额”“准时交付率”“库存周转率”写出指标口径。

习题 2.11. 某企业将每日转化率直接平均得到月度转化率。请构造一个两天的数值例子，说明这种做法可能产生误导，并给出正确计算方式。

习题 2.12. 考虑客户等级从普通客户升级为关键客户的场景。请说明在分析历史销售额时，使用当前客户等级和使用历史客户等级会回答两个不同问题。

本讲小结

本讲建立了企业数据建模的基础语言。实体、关系、事件、状态和指标是企业数据的基本语义单位；关系模型提供元组、属性、键、外键和完整性约束的形式基础；ER 模型帮助我们从业务对象出发讨论结构；规范化模型适合事务一致性，星型模型适合分析查询；事实表粒度、度量可加性和时间口径决定 KPI 是否可信；表到业务对象的映射则决定分析结果能否进入管理行动。后续课程的 SQL KPI、数据质量、看板、预测、优化和流程挖掘都将建立在这些概念之上。

常见误区

1. 不区分订单头与订单明细，导致事实表粒度混乱；
2. 使用业务含义不稳定的字段作为唯一主键；
3. 只画 ER 图，不说明主外键和完整性约束；
4. 将库存快照误认为交易事件；
5. 在 KPI 计算前没有定义指标口径和事实表粒度；
6. 对比率、百分比和均值进行简单相加或平均；
7. 用当前维度属性解释历史事件，却没有说明时间口径；
8. 把关系表直接等同于业务对象，忽略行动、权限和状态。

参考文献

- [1] Codd, E. F. (1970). A relational model of data for large shared data banks. *Communications of the ACM*, 13(6), 377–387.
- [2] Chen, P. P. (1976). The entity-relationship model: Toward a unified view of data. *ACM Transactions on Database Systems*, 1(1), 9–36.
- [3] Date, C. J. (2003). *An Introduction to Database Systems*. Addison-Wesley.
- [4] DAMA International. (2017). *DAMA-DMBOK: Data Management Body of Knowledge*, 2nd edition. Technics Publications.
- [5] Golfarelli, M., and Rizzi, S. (2009). *Data Warehouse Design: Modern Principles and Methodologies*. McGraw-Hill.
- [6] Inmon, W. H. (2005). *Building the Data Warehouse*. Wiley.
- [7] Kimball, R., and Ross, M. (2013). *The Data Warehouse Toolkit: The Definitive Guide to Dimensional Modeling*. Wiley.