

《大数据与管理决策基础》

第 10 讲：流程数据与过程挖掘

课程讲义

目录

第 10 讲 流程数据与过程挖掘	3
10.1 学习目标	3
10.2 为什么需要流程数据	4
10.3 事件日志的数据模型	4
10.4 case、event 与属性粒度	5
10.5 过程挖掘的三类任务	5
10.6 Directly-Follows Graph	6
10.7 流程变体与返工	6
10.8 瓶颈与流程绩效	6
10.9 合规检查与参考流程	7
10.10 资源视角与组织改进	7
10.11 第 10 周实验案例	7
10.12 数据质量与解释边界	8
10.13 从流程发现到流程改进	9
本讲小结	9
习题	9
常见误区	9
参考文献	10

第 10 讲 流程数据与过程挖掘

前几讲已经从指标、统计、预测、因果和优化角度讨论管理决策。本讲转向企业流程。许多经营问题不是单点指标异常，而是跨部门流程中的等待、返工、跳步、重复审批和执行偏差。过程挖掘把信息系统中的事件日志转化为流程证据：每个 case 的活动序列形成 trace，多个 trace 形成 variant，活动之间的相邻关系形成 directly-follows graph，时间戳允许计算吞吐时间和等待时间。讲义首先介绍事件日志的数据模型；随后讨论过程发现、合规检查和流程增强三类任务；再用 order-to-cash 案例说明如何识别瓶颈、返工和流程异常；最后讨论流程数据质量与管理改进边界。

课程接口

第 9 讲把预测和约束转化为最优行动，但行动通常嵌入流程中执行。若流程存在等待、返工或合规例外，最优决策也可能在执行层失效。本讲把“业务流程”变成可度量的数据对象，为现代数据平台、流程治理、自动化系统和企业决策闭环提供基础。

10.1 学习目标

完成本讲后，学生应能够：

1. 解释 case id、activity、timestamp、resource、trace 和 variant 的含义；
2. 将订单、工单、审批或履约过程整理为事件日志；
3. 计算流程变体、吞吐时间、活动频次和 directly-follows graph；
4. 区分过程发现、合规检查和流程增强三类过程挖掘任务；
5. 使用事件日志识别瓶颈、返工、跳步和活动顺序异常；
6. 理解事件时间戳、活动命名、case 边界和日志完整性对结论的影响；
7. 将过程挖掘结果写成面向流程改进的管理建议。

10.2 为什么需要流程数据

传统 dashboard 往往按日期、部门、区域或产品汇总指标。它能告诉管理者“平均履约周期较长”或“准时率下降”，但未必说明延迟发生在流程中的哪一步。过程挖掘关注的是业务对象随时间经过的活动序列。例如 order-to-cash 流程从接收订单开始，经过信用检查、拣货、质检、包装、发货、开票和收款。每一个订单就是一个 case，每个系统记录的活动就是一个 event。

流程问题常具有以下特征：

1. 跨部门：销售、财务、仓储、物流和客服共同影响结果；
2. 时序性：活动顺序和等待时间本身就是证据；
3. 多变体：同一流程存在标准路径、跳步路径、返工路径和异常路径；
4. 可执行：流程改进通常要求改变职责、系统规则、审批门槛或资源配置。

因此，流程数据不是普通明细表。它必须保留 case、activity 和 timestamp 三个核心维度，才能支持流程层面的分析。

10.3 事件日志的数据模型

定义 10.1 (事件日志). 事件日志是由事件组成的数据集合。每个事件至少包含：

1. case id：事件所属的流程实例；
2. activity：事件对应的业务活动；
3. timestamp：事件发生或完成的时间；
4. resource：执行活动的人、系统、部门或设备，若可得；
5. attributes：订单金额、客户分层、区域、产品等业务属性。

对 case c ，将其事件按时间排序得到 trace：

$$\sigma_c = (a_{c1}, a_{c2}, \dots, a_{cm_c}),$$

其中 a_{cj} 是第 j 个活动。若两个 case 的活动序列完全相同，则它们属于同一个 variant。variant 用于回答“流程实际有多少种走法”，而不是只依赖制度流程图中的理想路径。

定义 10.2 (吞吐时间). case c 的吞吐时间为最后一个事件与第一个事件之间的时间差：

$$T_c = t_{c,m_c} - t_{c,1}.$$

活动边 (a, b) 的等待时间通常由相邻事件 $a \rightarrow b$ 的时间差估计。

事件日志的质量直接决定过程挖掘质量。若 case id 错误，多个订单会被拼成一个流程；若 timestamp 缺失或时区混乱，瓶颈结论会失真；若 activity 命名不一致，同一个活动会被错误拆分。

10.4 case、event 与属性粒度

流程数据最常见的错误是粒度混乱。case 是流程实例，event 是流程实例中的一个活动记录，attribute 则描述 case 或 event 的业务属性。订单金额通常是 case 属性，因为它对同一订单的所有事件相同；执行人通常是 event 属性，因为不同活动可能由不同人员或系统执行；区域可能是 case 属性，也可能随配送活动变化，需要根据业务含义确定。

表 10.1: 流程数据粒度示例

层级	示例字段	典型用途
case	订单号、客户、订单金额、区域	计算吞吐时间、客户影响和高价值订单延迟。
event	活动名、时间戳、执行资源	构造 trace、计算等待时间和资源负载。
variant	活动序列、case 数、占比	识别标准路径、返工路径和例外路径。

如果粒度不清，过程挖掘会产生误导。例如把一张订单拆成多个履约单后，case 数会增加，吞吐时间会缩短；把多个订单合并为客户级 case，则 trace 会交织多个独立流程。

10.5 过程挖掘的三类任务

过程挖掘通常包含三类任务。

表 10.2: 过程挖掘任务

任务	目标	管理问题
过程发现	从事件日志自动构造流程模型或 directly-follows graph。	实际流程是否与制度流程一致？主要路径和例外路径是什么？
合规检查	比较事件日志与参考流程模型。	是否存在跳步、反序、缺失审批或违规执行？
流程增强	将时间、资源、成本、质量等信息叠加到流程模型。	哪些环节最慢、最贵、最容易返工或造成客户影响？

课程中不要求实现复杂的 Petri net 发现算法，而是从直接跟随关系和流程变体入手。这足以支撑许多管理场景中的第一轮流程诊断。

10.6 Directly-Follows Graph

给定每个 case 的 trace, 若活动 a 在某个 case 中紧接着活动 b , 则记为一条 directly-follows edge:

$$a \rightarrow b.$$

统计所有 case 中的相邻活动对, 可以得到 directly-follows graph。边的频次为

$$N_{ab} = \sum_c \sum_{j=1}^{m_c-1} \mathbf{1}\{a_{cj} = a, a_{c,j+1} = b\}.$$

边上的平均耗时可以写为

$$\bar{\Delta}_{ab} = \frac{1}{N_{ab}} \sum_{c,j:a_{cj}=a, a_{c,j+1}=b} (t_{c,j+1} - t_{cj}).$$

若某条边频次高且平均耗时长, 它通常是流程改进的优先候选; 若某条边频次低但业务风险高, 例如发货前未质检, 也应进入合规审查。过程挖掘的价值不在于画出复杂图, 而在于把路径、时间和异常组织成可讨论的事实。

10.7 流程变体与返工

流程变体揭示实际执行并不总是遵循标准路径。标准 order-to-cash trace 可以写成:

`order_received` $\rightarrow$ `credit_check` $\rightarrow$ `pick_items` $\rightarrow$ `quality_check` $\rightarrow$
`pack_order` $\rightarrow$ `ship_order` $\rightarrow$ `invoice_sent` $\rightarrow$ `payment_received`.

若某个 case 出现 `rework_pick` 并再次质检, 说明存在返工; 若缺少 `credit_check`, 说明可能存在跳步; 若 `invoice_sent` 出现在发货之前, 说明活动顺序可能违反业务规则。

返工不是天然坏事。某些返工可能是质量控制发挥作用的证据。但若返工集中在某类产品、仓库或客户分层, 就需要进一步分析根因。流程变体分析的目标不是消灭所有例外, 而是识别哪些例外有业务合理性, 哪些例外反映系统、组织或数据问题。

10.8 瓶颈与流程绩效

流程绩效至少应同时看三类指标:

1. case 级指标: 吞吐时间、事件数、是否返工、是否异常;
2. 活动级指标: 活动频次、资源负载、活动持续时间;
3. 边级指标: 相邻活动之间的等待时间、转移频次和异常跳转。

瓶颈不一定是活动本身最慢, 也可能是活动之间的等待。例如开票后到收款之间的时间差很长, 这不是系统处理慢, 而可能是账期、催收、客户信用或合同条款问题。过程挖掘帮助管理者定位“时间消失在哪里”, 但原因解释仍需要业务上下文。

10.9 合规检查与参考流程

合规检查需要先定义参考流程。参考流程可以来自制度文件、系统配置、审计规则或业务专家共识。常见规则包括：订单必须先完成信用检查再拣货，质检必须发生在包装之前，发货前不能开票，某些高金额订单必须经过额外审批。

定义 10.3 (合规异常). 合规异常是事件日志中的 trace 与参考流程规则不一致的情况。异常可能是真实违规，也可能是允许的业务例外、系统补录或日志缺失。

因此，合规异常不能立即等同于违规。过程挖掘给出的是线索：哪些 case 需要复核，哪些规则经常被绕开，哪些系统记录缺失。最终解释需要结合业务规则、审批记录和访谈。

10.10 资源视角与组织改进

若日志包含 resource 字段，就可以分析资源负载和交接。一个流程可能没有明显活动瓶颈，但在跨部门交接处长期等待；也可能某个团队活动频次不高，却承担大量高价值或高风险订单。资源视角可以回答：

1. 哪些团队或系统承担了最多活动；
2. 哪些资源处理的 case 吞吐时间更长；
3. 返工是否集中在某些班组、仓库或产品线；
4. 异常路径是否与特定人员、区域或系统版本有关。

资源分析要避免简单排名。若某个团队处理的是更复杂订单，平均耗时较长未必说明效率低；若某个资源的活动数很少，却负责关键审批，也不能只用吞吐量评价。流程分析应结合订单类型、金额、复杂度和客户影响。

10.11 第 10 周实验案例

本周样例数据位于：

`data/sample/order_to_cash_event_log.csv`

数据粒度为一行一个事件，字段包括 case_id、event_id、activity、timestamp、resource、order_value 和 region。

配套代码位于：

`src/bdm_decision/cases/week10_process_mining.py`

核心过程挖掘工具位于：

`src/bdm_decision/process\_mining/event\_log.py`

最小运行方式为：

代码 10.1: 运行第 10 周过程挖掘案例

```
PYTHONPATH=src python3 src/bdm_decision/cases/week10_process_mining.py
```

样例日志包含 67 个事件、8 个 case 和 4 个流程变体。平均吞吐时间为 114.88 小时。前两个变体如下：

变体	case 数	占比	平均吞吐时间
V01 标准路径	4	50.00%	102.75
V02 返工路径	2	25.00%	183.00

前若干条 directly-follows edge 为：

边	频次	平均小时
pack_order → ship_order	8	16.25
pick_items → quality_check	8	4.50
credit_check → pick_items	7	9.29
invoice_sent → payment_received	7	71.57

最慢的平均边为 `invoice_sent → payment_received`，平均耗时 71.57 小时。返工 case 为 `02C003` 和 `02C006`。合规异常包括：`02C004` 缺少 `credit_check`，`02C007` 存在活动顺序异常。这些发现指向三个改进方向：收款周期管理、仓储返工根因分析和流程规则执行。

10.12 数据质量与解释边界

过程挖掘对数据质量非常敏感。管理报告应检查：

1. case 边界是否清晰，一个订单是否可能拆成多个履约单；
2. timestamp 表示开始时间还是完成时间；
3. 系统时间是否存在时区、批量写入或补录；
4. activity 名称是否稳定，是否存在同义词或粒度混乱；
5. resource 字段是否真实反映执行者；
6. 例外路径是违规、业务规则还是数据缺失；
7. 流程发现是否连接到订单金额、客户影响和服务水平。

过程挖掘不是只看平均吞吐时间。一个流程可以平均时间不长，但存在少数高价值订单长期卡住；也可以总体合规，却在某个区域反复返工。优秀的流程分析应把路径、时间、金额、客户和组织责任结合起来。

10.13 从流程发现到流程改进

过程挖掘报告应避免只展示图和指标。流程改进需要把发现转化为可执行问题：

1. 若 `invoice_sent` 到 `payment_received` 最慢，应区分账期、催收、客户信用和发票错误；
2. 若返工路径吞吐时间显著更长，应追踪返工原因、产品类别、仓库班组和质检规则；
3. 若缺少信用检查，应确认是系统日志缺失、低风险订单允许跳过，还是实际绕开控制；
4. 若活动顺序异常，应检查时间戳含义、补录机制和流程规则。

一个成熟的流程改进闭环包括：发现问题、复核日志、访谈业务、提出规则或资源调整、实施试点、监控新日志、比较改进前后指标。过程挖掘本身不是改进，只有进入组织行动和反馈，才成为管理工具。

本讲小结

本讲介绍了流程数据与过程挖掘的基础。事件日志通过 `case id`、`activity` 和 `timestamp` 将业务流程转换为可计算对象；`trace` 和 `variant` 揭示实际路径；`directly-follows graph` 展示相邻活动关系；吞吐时间和边耗时用于定位等待和瓶颈；合规检查用于识别缺失、跳步和反序。`order-to-cash` 案例显示，流程改进应同时关注支付延迟、仓储返工、例外路径和数据质量。

习题

习题 10.4. 围绕 `data/sample/order_to_cash_event_log.csv` 完成下列任务：

1. 统计事件数、`case` 数和流程变体数；
2. 给出前两个流程变体的 `case` 数、占比和平均吞吐时间；
3. 构造 `directly-follows edge` 表，找出平均耗时最长的边；
4. 列出返工 `case` 和合规异常 `case`；
5. 选择一个合规异常，写出至少两种可能解释；
6. 写一段不超过 400 字的管理建议，说明 `order-to-cash` 流程应优先改进哪些环节。

常见误区

1. 把事件日志当作普通明细表，忽视 `case` 边界和活动顺序；
2. 只看平均吞吐时间，不看变体、返工和长尾 `case`；

3. 把发现的流程图当作制度流程，而不检查例外路径；
4. 不区分活动处理时间和活动之间的等待时间；
5. 忽视 timestamp 质量、补录和系统批处理造成的偏差；
6. 将所有合规异常都解释为违规，而不确认业务规则和数据缺失；
7. 只给出流程图，不连接订单金额、客户影响和责任部门。

参考文献

- [1] van der Aalst, W. M. P. (2016). *Process Mining: Data Science in Action*. Springer.
- [2] van der Aalst, W. M. P. et al. (2012). Process mining manifesto. *Business Process Management Workshops*, 169-194.
- [3] Dumas, M., La Rosa, M., Mendling, J., and Reijers, H. A. (2018). *Fundamentals of Business Process Management*. Springer.
- [4] IEEE Computational Intelligence Society. (2016). IEEE Standard for eXtensible Event Stream (XES) for achieving interoperability in event logs and event streams. IEEE Std 1849-2016.
- [5] Weske, M. (2019). *Business Process Management*. Springer.
- [6] Munoz-Gama, J. (2018). *Conformance Checking and Diagnosis in Process Mining*. Springer.