

第 7 讲：预测模型基础

从监督学习、泛化误差到客户流失行动清单

《大数据与管理决策基础》

核心命题：预测模型输出的是未来风险判断，管理决策还必须结合成本、容量和行动效果。

本讲学习目标

- ① 将管理预警问题写成监督学习问题；
- ② 理解特征、标签、训练集、测试集和损失函数；
- ③ 解释过拟合、交叉验证和泛化误差；
- ④ 计算分类模型的核心评价指标；
- ⑤ 区分排序能力、概率校准和阈值决策；
- ⑥ 将客户流失概率转化为留存行动候选清单。

课程主线中的第 7 周



第 7 周回答：在当前状态下，未来最可能发生什么，哪些对象需要提前关注？

预测问题的统一表达

$$Y = f(X) + \varepsilon, \quad \hat{f}: \mathcal{X} \rightarrow \mathcal{Y}.$$

管理问题	预测形式
客户流失	$\hat{\mathbb{P}}(Y = 1 \mid X = x)$
需求预测	$\hat{y}_{t+h}$
订单延期	逾期概率或预计延期天数
设备故障	故障风险排序

预测关系不等于因果关系；模型输出也不是行动本身。

监督学习的基本元素

$$\mathcal{D} = \{(x_i, y_i) : i = 1, \dots, n\}.$$

- ▶ x_i : 特征, 来自当前或过去可观察状态;
- ▶ y_i : 标签, 来自未来窗口或已发生结果;
- ▶ $\mathcal{D}_{\text{train}}$: 估计模型参数;
- ▶ $\mathcal{D}_{\text{test}}$: 评估未见样本表现;
- ▶ $\ell(y, \hat{y})$: 定义预测错误的损失函数。

治理提醒

特征必须在真实预测时可获得, 否则就是数据泄漏。

经验风险最小化

$$\hat{f} = \arg \min_{f \in \mathcal{F}} \frac{1}{n} \sum_{i=1}^n \ell(y_i, f(x_i)) + \lambda \Omega(f).$$

项目	含义
ℓ	错误如何被惩罚。
$\mathcal{F}$	候选模型类。
$\Omega(f)$	复杂度惩罚。
λ	拟合与稳健之间的权衡。

常用损失函数

回归：均方误差


$$\ell(y, \hat{y}) = (y - \hat{y})^2.$$

二元分类：交叉熵

$$\ell(y, \hat{p}) = -y \log(\hat{p}) - (1 - y) \log(1 - \hat{p}).$$

损失函数决定模型优化目标，也影响模型与管理成本之间的关系。

过拟合与泛化



模型选择的目标不是训练集最低误差，而是新样本上的最低可解释风险。

分类模型: confusion matrix

	预测正	预测负
实际正	TP	FN
实际负	FP	TN

$$\text{Precision} = \frac{TP}{TP + FP}, \quad \text{Recall} = \frac{TP}{TP + FN}.$$

$$F1 = \frac{2PR}{P + R}.$$

precision 关注误报成本, recall 关注漏报成本。

排序、概率与校准

- ▶ Accuracy: 固定阈值下的正确比例;
- ▶ ROC AUC: 正样本排在负样本前面的概率;
- ▶ Log loss: 概率预测的交叉熵损失;
- ▶ Calibration: 预测为 0.7 的对象是否长期约有 70% 发生。

管理含义

排序好不等于概率准; 概率准才更适合进入预算、收益和风险计算。

第 7 周客户流失数据

字段	含义
tenure_months	客户关系时长
monthly_spend	月消费金额
support_tickets_90d	90 天客服工单数
discount_rate	当前折扣率
usage_sessions_30d	30 天使用会话数
late_delivery_count_90d	90 天履约延迟次数
churned	是否流失标签

训练集 20 条，测试集 10 条；两者流失率均为 0.5000。

逻辑回归模型

$$\hat{p}_i = \frac{1}{1 + \exp[-(\beta_0 + \beta^\top z_i)]}.$$

特征	系数
客户关系时长	-2.2397
90 天客服工单数	1.1511
30 天使用会话数	-1.0217
折扣率	0.8472
履约延迟次数	0.6323
月消费	0.3712

系数方向可解释，但它们仍是预测关系，不是因果效应。

测试集指标

指标	数值
TP, FP, TN, FN	5, 1, 4, 0
Accuracy	0.9000
Precision	0.8333
Recall	1.0000
F1	0.9091
ROC AUC	1.0000
Log loss	0.1397

样例数据很小，因此指标只能用于教学说明，不能当作真实上线证据。

风险排序不是行动排序

客户	流失概率	月消费	预期净价值
C030	0.9995	72	-1.00
C028	0.9988	460	182.10
C021	0.9959	84	4.53
C025	0.9848	405	153.45
C023	0.9279	170	39.53

关键区别

最高风险客户不一定最值得行动；行动排序还要看成本、价值和干预效果。

```
PYTHONPATH=src python3 src/bdm_decision/cases/week07_prediction.py
```

```
from bdmd_decision.cases.week07_prediction import train_week07_churn_model
from bdmd_decision.models.churn_model import plan_retention_actions

model, train, test = train_week07_churn_model()
actions = plan_retention_actions(model, test)
print(actions[:3])
```

课堂讨论

- ① 如果漏报一个真实流失客户成本很高，阈值应提高还是降低？
- ② 为什么 accuracy 不能单独决定模型是否上线？
- ③ C030 风险最高却不建议优惠，是否合理？
- ④ 哪些字段可能造成数据泄漏？
- ⑤ 预测模型如何与 A/B 测试结合，评估留存行动是否真的有效？

本讲小结

- ▶ 预测模型估计未来结果，不自动给出因果解释；
- ▶ 损失函数和经验风险定义训练目标；
- ▶ 测试集和交叉验证用于控制泛化风险；
- ▶ 分类评估需要同时看阈值、排序、概率和校准；
- ▶ 阈值选择应服务业务成本、容量和风险偏好；
- ▶ 从预测到行动还需要干预效果、治理和反馈闭环。