

## 第 8 讲：因果推断与管理干预

### 从预测风险到评估行动是否改变结果

《大数据与管理决策基础》

核心命题：预测告诉我们谁更可能出问题，因果推断告诉我们行动是否真的改变结果。

# 本讲学习目标

- ① 区分相关、预测和因果；
- ② 用潜在结果表达管理干预效果；
- ③ 理解反事实、混杂和选择偏差；
- ④ 说明随机实验为何是识别基准；
- ⑤ 掌握倾向得分、分层和逆概率加权的直觉；
- ⑥ 使用 DID 评估前后政策变化；
- ⑦ 将因果估计写成带假设的管理建议。

## 课程主线中的第 8 周



第 7 周回答“谁更可能流失”，第 8 周回答“对谁采取行动是否真的有效”。

# 预测问题与因果问题

## 预测

$$\hat{\mathbb{P}}(Y = 1 \mid X = x)$$

在当前状态下，客户有多大可能流失？

## 因果

$$Y(1) - Y(0)$$

如果发放优惠券，相比不发券，结果是否改变？

高风险客户更可能收到优惠券，也更可能流失；因此处理组结果不能直接解释为处理效果。

# 潜在结果

对个体  $i$ :

$Y_i(1)$  = 接受处理时的结果,       $Y_i(0)$  = 不接受处理时的结果.

$$Y_i = D_i Y_i(1) + (1 - D_i) Y_i(0).$$

$$ATE = \mathbb{E}[Y(1) - Y(0)], \quad ATT = \mathbb{E}[Y(1) - Y(0) \mid D = 1].$$

## 基本因果问题

同一个体不能同时观察  $Y_i(1)$  和  $Y_i(0)$ , 其中一个永远是反事实。

# 相关、预测、因果

| 任务             | 典型问题                                     | 主要风险                                    |
|----------------|------------------------------------------|-----------------------------------------|
| 相关<br>预测<br>因果 | 工单数是否与流失同向变化？<br>谁未来最可能流失？<br>优惠券是否提高留存？ | 把共同变化当作原因。<br>把特征解释成干预对象。<br>忽视混杂和识别假设。 |

# 随机实验是识别基准

若处理分配随机：

$$D_i \perp (Y_i(1), Y_i(0)).$$

则

$$\mathbb{E}[Y \mid D = 1] - \mathbb{E}[Y \mid D = 0] = \mathbb{E}[Y(1) - Y(0)].$$

## 管理含义

随机化让处理组和对照组在设计上可比；观测性方法必须用假设和调整努力恢复这种可比性。


# 观测性因果识别假设

- ▶ 一致性：观察结果等于实际接受处理版本下的潜在结果；
- ▶ SUTVA：个体之间没有处理溢出，处理没有隐藏版本；
- ▶ 条件可交换性： $(Y(1), Y(0)) \perp D \mid X$ ；
- ▶ 重叠性： $0 < \mathbb{P}(D = 1 \mid X = x) < 1$ 。

## 课堂提醒

这些假设不能由软件自动保证，必须结合业务机制判断。

## 混杂与选择偏差



若高风险客户更容易被发券，朴素比较同时包含优惠券效果和原始风险差异。

$$e(X) = \mathbb{P}(D = 1 \mid X).$$

- 分层：在相近风险或相近倾向得分内比较；
- 匹配：寻找处理组和对照组中的相近对象；
- 加权：处理组权重  $1/e(X)$ ，对照组权重  $1/(1 - e(X))$ ；
- 平衡检查：调整后协变量差异是否降低。

$$\widehat{ATE}_{IPW} = \frac{1}{n} \sum_i \left[ \frac{D_i Y_i}{\hat{e}(X_i)} - \frac{(1 - D_i) Y_i}{1 - \hat{e}(X_i)} \right].$$

## 第 8 周观测性优惠券数据

| 方法   | 处理组均值  | 对照组均值  | 效果     |
|------|--------|--------|--------|
| 朴素差异 | 0.7500 | 0.7500 | 0.0000 |
| 风险分层 | 0.7500 | 0.7500 | 0.2500 |
| IPW  | NA     | NA     | 0.2199 |

### 解释

朴素差异为 0，不代表优惠券无效；处理组中高风险客户更多，原始比较被选择偏差抵消。

## 加权前后的平衡

| 特征              | 原始 SMD  | 加权 SMD  |
|-----------------|---------|---------|
| risk score      | 0.9710  | 0.2243  |
| tenure months   | -1.0255 | -0.3551 |
| monthly spend   | -1.0310 | -0.3600 |
| support tickets | 1.0180  | 0.3257  |
| usage sessions  | -1.0033 | -0.3079 |

加权改善了可比性，但没有证明未观察混杂已经消失。

# 差分中的差分

$$\hat{\tau}_{DID} = (\bar{Y}_{T,post} - \bar{Y}_{T,pre}) - (\bar{Y}_{C,post} - \bar{Y}_{C,pre}).$$

## 平行趋势假设

若没有干预，处理组和对照组的平均结果变化趋势应相同。

DID 用对照组同期变化校正共同时间冲击，但不能自动处理不同趋势、溢出和同期政策变化。

## 第 8 周 DID 数据

| 组别   | 干预前    | 干预后    | 变化     |
|------|--------|--------|--------|
| 处理门店 | 0.6100 | 0.7025 | 0.0925 |
| 对照门店 | 0.7125 | 0.7275 | 0.0150 |

$$\hat{\tau}_{DID} = 0.0925 - 0.0150 = 0.0775.$$

在平行趋势假设下，留存策略使处理门店留存率额外提高约 7.75 个百分点。

# 代码入口

```
PYTHONPATH=src python3 src/bdm_decision/cases/week08_causality.py
```

```
from bdms_decision.causal.propensity_score import (  
    load_coupon_records, naive_difference, risk_band_adjusted_effect  
)  
from bdms_decision.causal.did import load_panel_records, difference_in_differences  
  
records = load_coupon_records()  
print(naive_difference(records))  
print(risk_band_adjusted_effect(records))  
print(difference_in_differences(load_panel_records()))
```

- ① 为什么朴素差异为 0 仍不能说明优惠券无效？
- ② 哪些未观察因素可能同时影响发券和留存？
- ③ 如果某类高风险客户全都被发券，重叠性会怎样失败？
- ④ DID 的平行趋势可以用哪些业务证据支持？
- ⑤ 预测模型、因果估计和优惠券预算应如何连接？

# 本讲小结

- ▶ 预测回答未来风险，因果回答行动效果；
- ▶ 潜在结果框架明确了反事实和处理效应；
- ▶ 随机实验是最清晰的识别基准；
- ▶ 观测性方法依赖一致性、SUTVA、可交换性和重叠性；
- ▶ 倾向得分改善可比性，但不能消除未观察混杂；
- ▶ DID 依赖平行趋势，应配合业务机制和前趋势检查。