

第 4 讲：数据质量、数据治理与指标可信度

质量维度、失败记录、质量门禁与指标治理

《大数据与管理决策基础》

核心命题：指标可信度不是从 SQL 开始，而是从输入数据、规则和责任开始。

本讲学习目标

- ① 解释数据质量如何影响管理 KPI;
- ② 区分完整性、唯一性、有效性、一致性、及时性和可追溯性;
- ③ 将质量维度转化为失败记录查询;
- ④ 设计数据剖析报告和质量门禁;
- ⑤ 说明数据治理与指标治理中的责任分工;
- ⑥ 生成一个可复核的数据质量报告。

从 KPI 公式回到数据假设

准时交付率：

$$\text{OTD} = \frac{\sum_i I(a_i \leq p_i)}{n}.$$

隐含假设

- ① 订单唯一且不会重复计数；
- ② 实际日期和承诺日期有效且可比较；
- ③ 未交付订单没有被误判为准时或延期；
- ④ 时间窗口和分母口径已经被定义。

数据质量的课程定义

Data Quality = Fitness for Use $\cap$ Conformance to Rules $\cap$ Traceability of Evidence.

管理含义

数据是否“好”，取决于它能否支持当前指标、模型、行动和审计。

常见质量维度

维度	基本问题	订单示例
完整性	必要字段是否存在？	缺少客户编号。
唯一性	对象是否重复？	订单号重复。
有效性	是否满足格式和取值域？	渠道值非法。
一致性	跨表是否矛盾？	客户外键不存在。
及时性	数据是否足够新？	交付结果延迟入仓。
可追溯性	能否追溯来源和版本？	指标无法复现。

质量规则：从断言到失败集合

设数据表为 $R = \{r_1, \dots, r_n\}$, 规则为谓词

$$\phi_j(r_i) \in \{0, 1\}.$$

失败集合为

$$F_j = \{r_i \in R : \phi_j(r_i) = 0\}.$$

工程化表达

质量测试应返回失败记录，而不只是返回一个抽象分数。

从质量维度到数据测试

测试	失败记录含义
not null	必填字段为空。
unique	主键或业务键重复。
relationships	外键无法连接到主数据。
accepted values	枚举字段出现未治理取值。
range check	数量、金额或日期超出业务边界。

失败记录查询示例

```
select order_id, count(*) as row_count  
from orders  
group by order_id  
having count(*) > 1;
```

```
select o.order_id, o.customer_id  
from orders as o  
left join customers as c  
  on o.customer_id = c.customer_id  
where c.customer_id is null;
```

复核原则

测试失败后，应能定位到具体记录、字段、规则和责任人。

数据剖析先于治理

- ① 行数与字段数；
- ② 每列缺失数和缺失率；
- ③ 不同值数量；
- ④ 数值字段最小值与最大值；
- ⑤ 日期字段范围；
- ⑥ 主键重复与外键不匹配。

质量问题如何扭曲 KPI

问题	影响机制	指标
订单重复	同一事实进入多次。	销售额、订单数。
外键缺失	内连接丢失事实。	区域收入。
数量为负	收入和毛利被扭曲。	毛利率。
日期错误	周期与延期判断失真。	准时率。
枚举不一致	分组口径不稳定。	渠道 KPI。

治理对象	关键问题
数据 owner	谁对业务定义负责？
data steward	谁维护字段含义和质量规则？
指标字典	指标名称、分子分母、时间窗口是否明确？
变更流程	口径变化如何审批和版本化？
审计记录	指标能否回到输入数据和代码版本？

级别	发布策略	示例
Error	阻止关键表或 KPI 发布。	主键重复、核心外键缺失。
Warning	发布但标记并跟踪。	新渠道值、少量缺失。
Info	记录趋势，用于改进。	分布轻微变化。

第 4 周实验交付

- ① 对 `orders_quality_issues.csv` 做字段剖析；
- ② 找出主键重复、外键缺失、非法枚举和日期错误；
- ③ 输出失败记录表；
- ④ 说明每类失败影响哪些 KPI；
- ⑤ 为准时交付率设计质量门禁；
- ⑥ 提交一页数据质量报告。

本讲小结

- ① 数据质量是指标可信度的前提；
- ② 质量维度必须转化为可执行规则；
- ③ 数据测试应返回失败记录；
- ④ 质量问题要连接到 KPI 影响和管理行动；
- ⑤ 治理的核心是定义、责任、版本和审计；
- ⑥ 下一讲进入统计描述与 dashboard。