

第 6 讲：统计推断、A/B 测试与管理判断

从 dashboard 差异到随机实验、置信区间与行动建议


《大数据与管理决策基础》

核心命题：指标差异不是行动结论，实验设计和不确定性评估才使差异进入管理决策。

本讲学习目标

- ① 区分描述统计、统计推断和因果评估；
- ② 理解样本、估计量、标准误、置信区间和 p 值；
- ③ 设计面向管理行动的 A/B 测试；
- ④ 用差异估计量评估主指标和护栏指标；
- ⑤ 理解 MDE、功效、样本量和重复窥探风险；
- ⑥ 将实验结果写成审慎的管理建议。

课程主线中的第 6 周



第 5 周回答“看起来发生了什么”，第 6 周回答“观察到的差异是否足以支持改变”。

从描述差异到推断问题

dashboard 只能给出观察结果

某个新版页面转化率更高，某个日期收入异常，某个渠道投诉率上升。

统计推断要回答

如果重复观察、扩大样本或推广行动，这种差异是否仍可能存在？

$$\bar{Y} = \frac{1}{n} \sum_{i=1}^n Y_i, \quad \text{SE}(\bar{Y}) = \frac{s}{\sqrt{n}}.$$

样本均值是估计，不是总体本身；管理报告应呈现不确定性。

A/B 测试的基本结构

元素	管理含义
实验单元	被随机分配的访客、订单、门店、销售人员或客户。
处理与对照	$T_i = 1$ 为处理组, $T_i = 0$ 为对照组。
主指标	决定实验是否达到核心目标, 如转化率。
护栏指标	防止局部优化损害体验、财务、运营或长期价值。
分析窗口	从分配到观察结果的时间边界。
决策规则	推广、继续实验、停止实验或回滚。

潜在结果与随机化

对实验单元 i , 设:

$Y_i(1)$ = 接受处理时的结果, $Y_i(0)$ = 接受对照时的结果.

个体处理效应:

$$\tau_i = Y_i(1) - Y_i(0).$$

平均处理效应:

$$\tau = \mathbb{E}[Y(1) - Y(0)].$$

随机化的价值

若处理分配与潜在结果独立, 组间平均差异可以作为处理效果的估计, 而不是选择偏差的直接产物。

$$\hat{\tau} = \bar{Y}_1 - \bar{Y}_0 = \frac{1}{n_1} \sum_{i:T_i=1} Y_i - \frac{1}{n_0} \sum_{i:T_i=0} Y_i.$$

$$\widehat{\text{SE}}(\hat{\tau}) = \sqrt{\frac{s_1^2}{n_1} + \frac{s_0^2}{n_0}}.$$

$$\hat{\tau} \pm z_{1-\alpha/2} \widehat{\text{SE}}(\hat{\tau}).$$

二元指标的样本均值就是比例，因此转化率也可以放入同一差异估计框架。

p 值不是什么

p 值是

在原假设成立时，观察到当前统计量或更极端统计量的概率。

p 值不是

处理有效的概率，也不是原假设为真的概率，更不是推广决策本身。

- ▶ 统计显著不等于业务值得推广；
- ▶ 不显著不等于没有效果；
- ▶ 小样本很容易产生方向正确但证据不足的结果；
- ▶ 决策还要看成本、风险、护栏和执行条件。

MDE 与样本量

MDE 是组织希望实验能够可靠识别的最小业务差异。

$$n \approx \frac{\left[z_{1-\alpha/2} \sqrt{2\bar{p}(1-\bar{p})} + z_{1-\beta} \sqrt{p_0(1-p_0) + p_1(1-p_1)} \right]^2}{(p_1 - p_0)^2}.$$

管理解释

MDE 不是统计软件参数，而是“多大改善值得行动”的管理声明。

护栏指标

类型	指标	作用
体验	页面加载时间、投诉率	防止转化提升损害体验。
财务	毛利率、补贴成本	防止收入来自不可持续成本。
运营	履约延迟、人工处理量	防止压力转移给运营团队。
长期	复购率、取消率	防止短期收益伤害长期价值。

实验报告必须同时呈现主指标和护栏指标。

第 6 周实验数据

组别	n	转化数	转化率	每访客收入
A	20	7	0.3500	16.95
B	20	11	0.5500	31.65

第一眼结论

B 组看起来转化更高、收入更高。

推断问题

这种差异是否足以支持全量推广？

实验结果：主指标仍不确定

指标	A 均值	B 均值	差异	95% CI
转化	0.3500	0.5500	0.2000	[-0.1099, 0.5099]
每访客收入	16.95	31.65	14.70	[-2.69, 32.09]

方向有吸引力，但置信区间跨越 0。当前样本不足以把“看起来更好”升级为“可以全量推广”。

护栏结果：页面加载变慢

指标	A 均值	B 均值	差异	95% CI
页面加载毫秒	443.75	495.40	51.65	[42.25, 61.05]
客服工单率	0.0500	0.1500	0.1000	[-0.0690, 0.2690]

管理含义

即使主指标方向较好，页面加载护栏已经明显恶化；应继续实验或优化方案，而不是立即全量上线。

代码入口

```
PYTHONPATH=src python3 src/bdm_decision/cases/week06_ab_testing.py
```

```
from bdmd_decision.cases.week06_ab_testing import load_checkout_experiment
from bdmd_decision.causal.ab_test import difference_in_means

records = load_checkout_experiment()
conversion = difference_in_means(records, "converted")
page_load = difference_in_means(records, "page_load_ms")
print(conversion)
print(page_load)
```

课堂讨论

- ❶ 如果你是产品负责人，是否会推广 B 组？为什么？
- ❷ 若只能继续收集一周数据，应优先扩大样本还是修改方案？
- ❸ 若 B 组只对新访客有效，是否可以做分层推广？
- ❹ 如果每天查看一次 p 值，实验停止规则应如何写？
- ❺ 护栏指标和主指标冲突时，谁拥有最终决策权？

本讲小结

- ▶ dashboard 差异需要统计推断才能进入行动判断；
- ▶ 随机化使组间差异具备因果解释的设计基础；
- ▶ 置信区间比单点估计更适合管理沟通；
- ▶ p 值不能替代业务成本、风险和护栏指标；
- ▶ MDE 和功效应在实验前确定；
- ▶ 第 8 讲将从随机实验扩展到非实验因果识别。