

第 10 讲：流程数据与过程挖掘

从事件日志到变体、瓶颈、返工与合规异常

《大数据与管理决策基础》

核心命题：流程不是静态图，而是由 case、activity 和 timestamp 构成的可计算行为证据。

本讲学习目标

- ① 理解事件日志的基本数据模型；
- ② 解释 case、activity、timestamp、trace 和 variant；
- ③ 构造 directly-follows graph；
- ④ 计算吞吐时间、边耗时和活动频次；
- ⑤ 识别返工、瓶颈和合规异常；
- ⑥ 将过程挖掘结果转化为流程改进建议。

课程主线中的第 10 周



优化方案只有进入流程执行后，才会暴露等待、返工、跳步和责任边界。

字段	含义
case id	一个流程实例，如订单、工单、申请。
activity	实际发生的业务活动。
timestamp	活动发生或完成时间。
resource	执行人、系统、部门或设备。
attributes	金额、区域、客户、产品等上下文。

$$\sigma_c = (a_{c1}, a_{c2}, \dots, a_{cm_c}).$$

按时间排序后的活动序列称为 trace。

过程挖掘三类任务

任务	目标	管理问题
过程发现	从日志构造流程模型。	实际流程怎样运行？
合规检查	比较日志与参考流程。	是否跳步、反序或缺失？
流程增强	叠加时间、资源、成本。	哪里慢、贵、易返工？

Directly-Follows Graph

若活动 a 在某个 case 中紧接活动 b ，记为：

$$a \rightarrow b.$$

- ▶ 边频次：路径常见程度；
- ▶ 平均耗时：相邻活动之间的等待或处理时间；
- ▶ 低频高风险边：可能是例外路径或合规问题；
- ▶ 高频长耗时边：通常是流程改进候选。

Variant

活动序列完全相同的 case 属于同一个流程变体。

- ▶ 标准路径：制度流程的主要执行方式；
- ▶ 跳步路径：缺少某些活动；
- ▶ 返工路径：活动重复或出现 rework；
- ▶ 异常路径：活动顺序违反参考流程。

变体分析回答：流程实际有多少种走法，哪些路径最常见、最慢、最风险。

第 10 周事件日志

指标	数值
事件数	67
case 数	8
流程变体数	4
平均吞吐时间	114.88 小时
返工 case	O2C003, O2C006

样例流程为 order-to-cash：接单、信用检查、拣货、质检、包装、发货、开票、收款。

主要流程变体

变体	case 数	占比	平均吞吐时间
V01 标准路径	4	50.00%	102.75
V02 返工路径	2	25.00%	183.00
V03 反序异常	1	12.50%	73.00
V04 跳过信用检查	1	12.50%	69.00

返工路径的平均吞吐时间明显高于标准路径。

Directly-Follows 结果

边	频次	平均小时
pack → ship	8	16.25
pick → quality	8	4.50
credit → pick	7	9.29
invoice → payment	7	71.57
order → credit	7	8.00

瓶颈候选

开票到收款平均 71.57 小时，是最慢的相邻活动边。

case	问题
O2C004	missing credit_check
O2C007	activity order violation

- ▶ 缺少信用检查可能是低风险快速通道，也可能是规则执行缺口；
- ▶ 发票早于发货可能是系统补录、特殊合同或真实流程反序；
- ▶ 异常解释必须回到业务规则和数据质量。

数据质量检查

- ▶ case id 是否稳定，一张订单是否拆成多个履约单？
- ▶ timestamp 是开始时间、完成时间还是补录时间？
- ▶ activity 命名是否一致，粒度是否稳定？
- ▶ resource 是否表示实际执行者？
- ▶ 例外路径是违规、允许路径还是数据缺失？
- ▶ 流程发现是否结合订单金额和客户影响？

代码入口

```
PYTHONPATH=src python3 src/bdm_decision/cases/week10_process_mining.py
```

```
from bdmddecision.process_mining.event_log import (  
    load_event_log, summarize_cases, summarize_variants,  
    directly_follows_graph  
)  
  
events = load_event_log()  
cases = summarize_cases(events)  
variants = summarize_variants(cases)  
edges = directly_follows_graph(events)
```

课堂讨论

- ① 为什么平均吞吐时间不能单独说明流程健康?
- ② invoice 到 payment 的长等待应由哪个部门负责?
- ③ O2C004 缺少信用检查一定是违规吗?
- ④ 如何判断返工是质量控制有效还是流程浪费?
- ⑤ 过程挖掘结果如何进入下一轮优化或自动化?

本讲小结

- ▶ 事件日志将流程转化为 case、activity 和 timestamp;
- ▶ trace 和 variant 揭示实际路径;
- ▶ directly-follows graph 展示相邻活动关系和等待;
- ▶ 过程挖掘包括发现、合规检查和流程增强;
- ▶ order-to-cash 案例暴露支付延迟、返工和异常路径;
- ▶ 流程结论必须结合时间戳质量、业务规则和客户影响。